


HERB-AI ***PLANT DISEASE CNN*** ***CLASSIFIER***

2211333 - Valentina Álvarez

2211848 - Diego García

2211861 - Erick Vargas





PLANT DISEASE CNN CLASSIFIER: HERB-AI

2211333 - Valentina Álvarez Valderrama

2211848 - Diego Garcia-Barajas

2211861- Erick Daniel Vargas





PROBLEMA

- Propagación rápida de plagas o infecciones de cultivos.
- Limitaciones de personal especializado.

OBJETIVO

Identificar y clasificar enfermedades que puedan afectar cultivos a través de la extracción de características que proporcionan las redes convolucionales, basado en las imágenes de hojas sanas y contaminadas.



DATASET

The classes are,

- 1.Apple_scab
- 2.Apple_black_rot
- 3.Apple_cedar_apple_rust
- 4.Apple_healthy
- 5.Background_without_leaves
- 6.Blueberry_healthy
- 7.Cherry_powdery_mildew
- 8.Cherry_healthy
- 9.Corn_gray_leaf_spot
- 10.Corn_common_rust
- 11.Corn_northern_leaf_blight
- 12.Corn_healthy
- 13.Grape_black_rot
- 14.Grape_black_measles
- 15.Grape_leaf_blight
- 16.Grape_healthy
- 17.Orange_haunglongbing
- 18.Peach_bacterial_spot
- 19.Peach_healthy
- 20.Pepper_bacterial_spot
- 21.Pepper_healthy
- 22.Potato_early_blight
- 23.Potato_healthy
- 24.Potato_late_blight
- 25.Raspberry_healthy
- 26.Soybean_healthy
- 27.Squash_powdery_mildew
- 28.Strawberry_healthy
- 29.Strawberry_leaf_scorch
- 30.Tomato_bacterial_spot
- 31.Tomato_early_blight
- 32.Tomato_healthy
- 33.Tomato_late_blight
- 34.Tomato_leaf_mold
- 35.Tomato_septoria_leaf_spot
- 36.Tomato_spider_mites_two-spotted_spider_mite
- 37.Tomato_target_spot
- 38.Tomato_mosaic_virus
- 39.Tomato_yellow_leaf_curl_virus



MÉTRICAS

$$\text{Precision} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}}$$

$$\text{Accuracy} = \frac{\text{Correct predictions}}{\text{All predictions}}$$

$$\text{Recall} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

$$\text{WeightedAvgPrecision} = \sum_{c \in \{\text{Classes}\}} \text{Precision} \cdot Wc$$

$$\text{WeightedAvgRecall} = \sum_{c \in \{\text{Classes}\}} \text{Recall} \cdot Wc$$

$$\text{WeightedF1Score} = 2 \cdot \left(\frac{\text{WeightedAvgPrecision} \cdot \text{WeightedAvgRecall}}{\text{WeightedAvgPrecision} + \text{WeightedAvgRecall}} \right)$$

$$\text{MacroAvgPrecision} = \frac{\sum_{c \in \{\text{Classes}\}} \text{Precision}_c}{|\{\text{Classes}\}|}$$

$$\text{MacroAvgRecall} = \frac{\sum_{c \in \{\text{Classes}\}} \text{Recall}_c}{|\{\text{Classes}\}|}$$


$$\text{MacroF1Score} = 2 \cdot \left(\frac{\text{MacroAvgPrecision} \cdot \text{MacroAvgRecall}}{\text{MacroAvgPrecision} + \text{MacroAvgRecall}} \right)$$






MODELO SELECCIONADO

VGGNET



Modelo 2: VGGNet. Tomado de <https://medium.com/@siddheshb008/vgg-net-architecture-explained-71179310050f>



VGGNET

Arquitectura del Modelo

Input Shape:

(128, 128, 3)



VGG16 Base (Preentrenado)

Conv2D + MaxPool (Block 1) - 64 filters

Conv2D + MaxPool (Block 2) - 128 filters

Conv2D + MaxPool (Block 3) - 256 filters

Conv2D + MaxPool (Block 4) - 512 filters

Conv2D + MaxPool (Block 5) - 512 filters

Weights: ImageNet | Top layers: Excluidas



Capas Personalizadas

GlobalAveragePooling2D()

Dropout(0.3)

Dense(num_classes, softmax)

Proceso de Entrenamiento

1

Transfer Learning

VGG16 Base:

Congelado
(trainable=False)

Optimizer:

Adam(lr=0.0001)

Loss:

sparse_categorical_crossentropy

Épocas:

10

2

Fine-tuning

Descongelado:

Capas 4+ (trainable=True)

Congelado:

Primeras 4 capas

Optimizer:

Adam(lr=1e-5)

Learning Rate:


Reducido para fine-tuning

Capas Congeladas (No entrenable)

Capas Entrenables

VGG16 Preentrenado

Capas Personalizadas








VGGNET



modelvgg16 - Loss



modelvgg16 - Accuracy





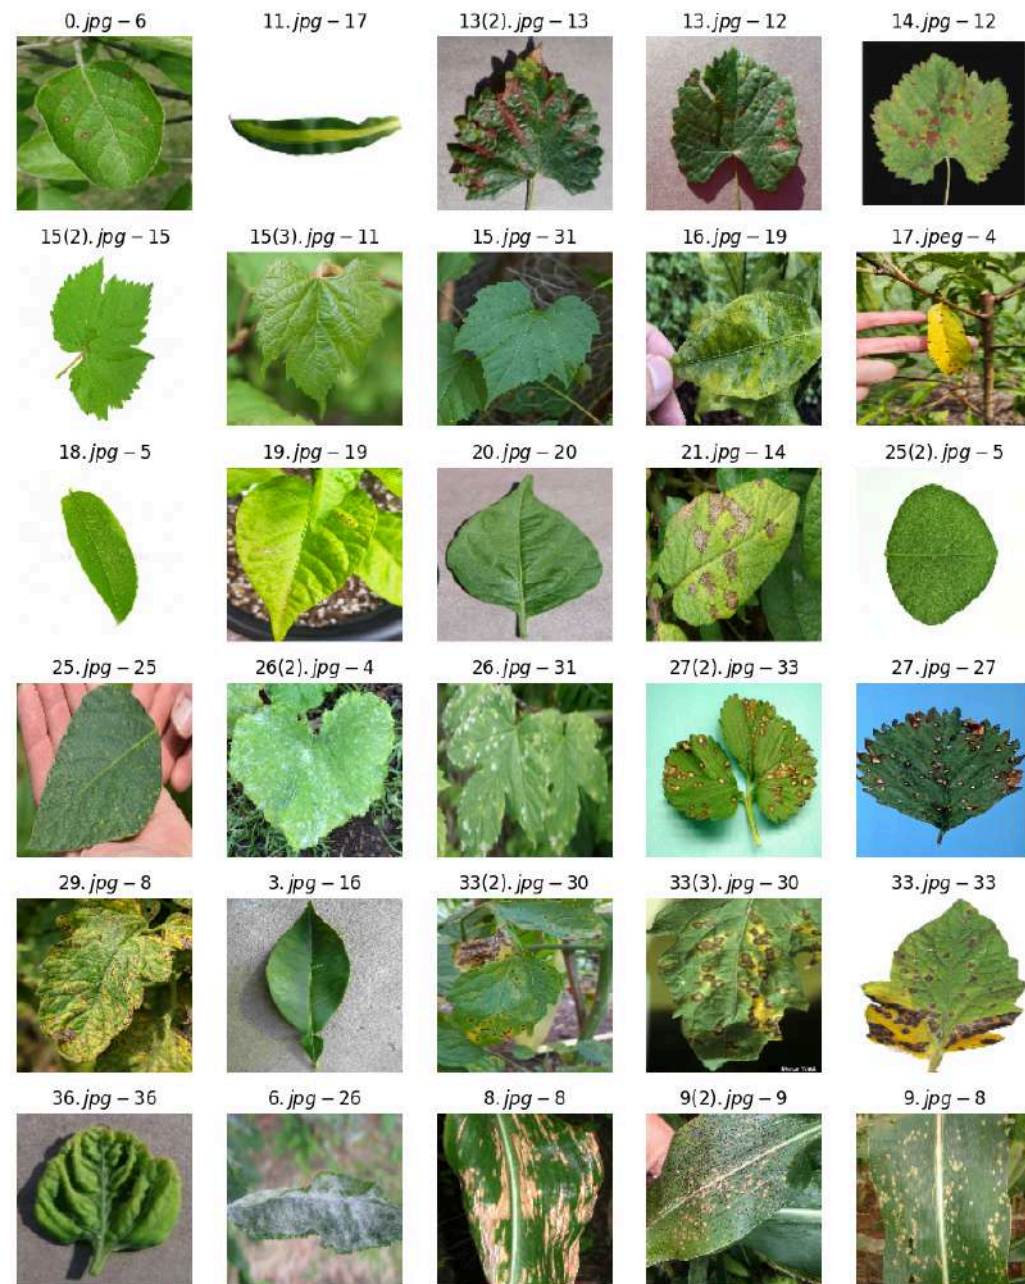
RESULTADOS Y ANÁLISIS

70-10-20

- Sklearn Accuracy: 0.9689
- Sklearn Macro Precision: 0.9669
- Sklearn Macro Recall: 0.9562
- Sklearn Macro F1-score: 0.9578
- Sklearn Weighted Precision: 0.9735
- Sklearn Weighted Recall: 0.9689
- Sklearn Weighted F1-score: 0.9683



Apple__Apple_scab	0	Potato__Early_blight	21
Apple__Black_rot	1	Potato__Late_blight	22
Apple__Cedar_apple_rust	2	Potato__healthy	23
Apple__healthy	3	Raspberry__healthy	24
Background_without_leaves	4	Soybean__healthy	25
Blueberry__healthy	5	Squash__Powdery_m	26
Cherry__Powdery_mildew	6	Strawberry__Leaf_sc	27
Cherry__healthy	7	Strawberry__healthy	28
Corn__Cercospora_leaf_spot Gray	8	Tomato__Bacterial_s	29
Corn__Common_rust	9	Tomato__Early_bligh	30
Corn__Northern_Leaf_Blight	10	Tomato__Late_blight	31
Corn__healthy	11	Tomato__Leaf_Mold	32
Grape__Black_rot	12	Tomato__Septoria_le	33
Grape__Esca_(Black_Measles)	13	Tomato__Spider_mit	34
Grape__Leaf_blight_(Isariopsis_L)	14	Tomato__Target_Spo	35
Grape__healthy	15	Tomato__Tomato_Ye	36
Orange__Haunglongbing_(Citrus_	16	Tomato__Tomato_m	37
Peach__Bacterial_spot	17	Tomato__healthy	38
Peach__healthy	18		
Pepper,_bell__Bacterial_spot	19		
Pepper,_bell__healthy	20		



13 (2).jpg
Predicción: 13




Imagen original



13.jpg
Predicción: 12




Imagen original



14.jpg
Predicción: 12




Imagen original



15 (2).jpg
Predicción: 15




Imagen original



Análisis GRADCAM

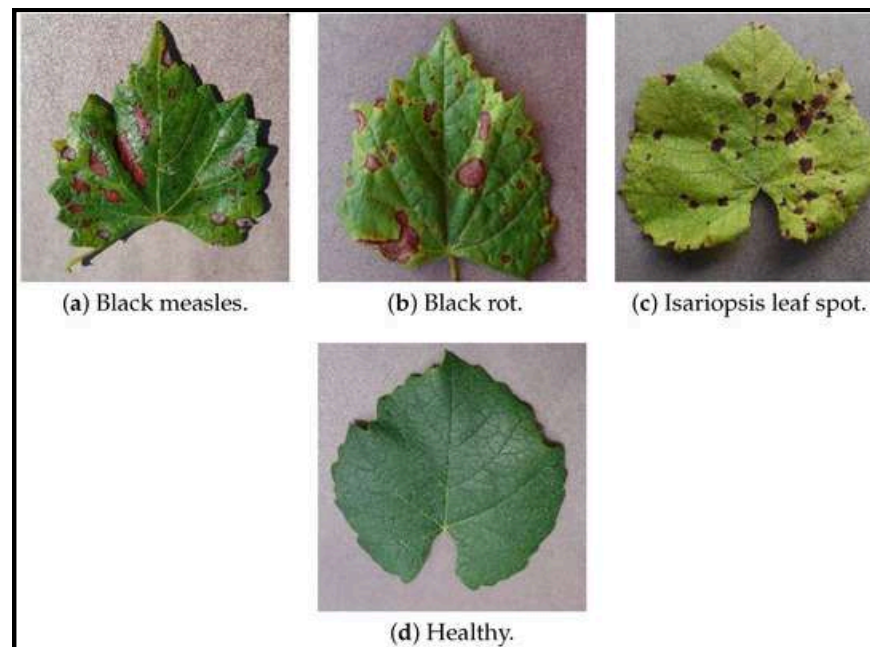


Figura 1: Enfermedades de la uva.

Tomado de <https://doi.org/10.3390/agriculture12101542>

Grape__Black_rot	12	1180
Grape__Esca_(Black_Measles)	13	1383
Grape__Leaf_blight_(Isariopsis_Leaf_Spot)	14	1076
Grape__healthy	15	423

Análisis GRADCAM

11.jpg
Predicción: 17




Imagen original



6.jpg
Predicción: 26




Imagen original



17.jpeg
Predicción: 4



Imagen original



27 (2).jpg
Predicción: 33




Imagen original



27.jpg
Predicción: 27




Imagen original



33 (2).jpg
Predicción: 30




Imagen original



33 (3).jpg
Predicción: 30




Imagen original



33.jpg
Predicción: 33





Imagen original



Análisis GRADCAM



Tomato__Early_blight	30
Tomato__Late_blight	31
Tomato__Leaf_Mold	32
Tomato__Septoria_leaf_spot	33



CONCLUSIONES

Conclusiones

- Reducir la cantidad de clases puede mejorar el rendimiento del modelo enfocándose en un solo tipo de cultivo.
- El análisis con Grad-Cam reveló problemas en la atención del modelo, presta atención a zonas irrelevantes como el fondo, lo que sugiere una necesidad de mejorar la calidad del dataset o aplicar técnicas de segmentación previa.
- El modelo mostro buen desempeño con el conjunto de validación y testeando, pero mal con imágenes externas extraídas de google, demostrando una escasa habilidad para generalizar en contextos reales.





TRABAJO FUTURO

Trabajo Futuro

- Combinar con un proceso previo de detección.
- Reentrenar con datasets menos sesgados (Fondo muy controlado).
- Tomar medidas para contrarrestar el desbalance de datos.





TURNO DE...

PREGUNTAS (fáciles)

COMENTARIOS (bonitos)

CRÍTICAS (constructivas)

APORTACIONES (monetarias)

¡GRACIAS!

